

Hallazgos del proceso

El objetivo de esta actividad fue transformar el dataset 01_DiatomInventories_GTstudentproject_B.csv de su estado inicial (incompleto y con valores extremos) a un conjunto de datos limpio y confiable apto para análisis posteriores. Se emplearon las librerías pandas, numpy, y matplotlib para realizar la importación, exploración, limpieza, y visualización de los datos.

Metodología de Limpieza y Preparación de Datos

1. Exploración Inicial

Tras la carga del archivo, se realizó una revisión de los datos, confirmando la presencia de valores nulos que hacían necesaria una etapa de limpieza. Las variables se categorizaron para un análisis estratégico: cuantitativas (numéricas) para el análisis estadístico y cualitativas (categóricas) para la frecuencia y el agrupamiento.

2. Detección y Manejo de Atípicos (Outliers)

Se generaron diagramas de caja (boxplots) para las columnas numéricas con el fin de visualizar los outliers. Los boxplots se hicieron para las variables Abundance_pm, TotalAbundance_SamplingOperation, y Abundance_nbcell. Para identificar formalmente los valores extremos, se utilizaron los límites definidos por la regla de ± 3 desviaciones estándar, resultando en un nuevo dataset filtrado que excluye dichos atípicos.

3. Estrategia de Imputación de Nulos

Los valores faltantes se trataron mediante la imputación por mediana. Esta técnica fue seleccionada porque permite mantener la coherencia en las variables numéricas sin la necesidad de eliminar registros completos, y los valores imputados fueron redondeados a una cifra decimal.

4. Construcción del Dataset Final

Una vez limpias las variables cuantitativas y procesados los nulos, estas se unieron con las variables cualitativas para formar un nuevo DataFrame denominado Datos_limpios. Se verificó exitosamente que el tratamiento de los valores nulos había sido efectivo.

Análisis de Frecuencias y Visualización

5. Análisis de Frecuencia

Se elaboraron tablas de frecuencia para las variables categóricas TaxonName (nombres de taxones) y TaxonCode (códigos de taxones). El análisis se centró en las categorías más representativas, aplicando un filtro para mostrar solo aquellas con más de 20,578 registros.

6. Representaciones Gráficas

- * Se utilizó un gráfico de barras para visualizar las categorías más frecuentes de TaxonName.

- * Se empleó un gráfico de área para representar las categorías más frecuentes de TaxonCode.

- * Un gráfico circular mostró la distribución del conteo de registros por fecha, revelando una distribución relativamente uniforme, siendo el 11 de julio de 2013 el valor más alto.

- * TaxonName Dominante: Achnanthes minutissima es la especie más frecuente, superando los 42,000 registros.

- * Taxones Secundarios: Le siguen Amphora pediculus, Cocconeis euglypta, Sellaphora nigris, y Navicula cryptotenella, con valores entre 38,000 y 40,000 registros.

- * Código de Taxón Principal: El código Achmi02 es el más dominante con más de 43,000 registros.

- * Códigos de Taxones Significativos: Coceu01 ($\approx 39,000$), Navcr09 ($\approx 38,000$), y Vibtr01 ($\approx 31,000$) también muestran una alta representación.

Conclusión Final

La implementación de la imputación por mediana y el filtrado de outliers con la regla de ± 3 desviaciones estándar resultó en un dataset más confiable y consistente. La estrategia de la mediana garantizó una mejor representación central de los datos. Este proceso asegura que el dataset final está optimizado para ser usado en análisis posteriores o modelos predictivos sin los problemas de calidad de datos iniciales.